

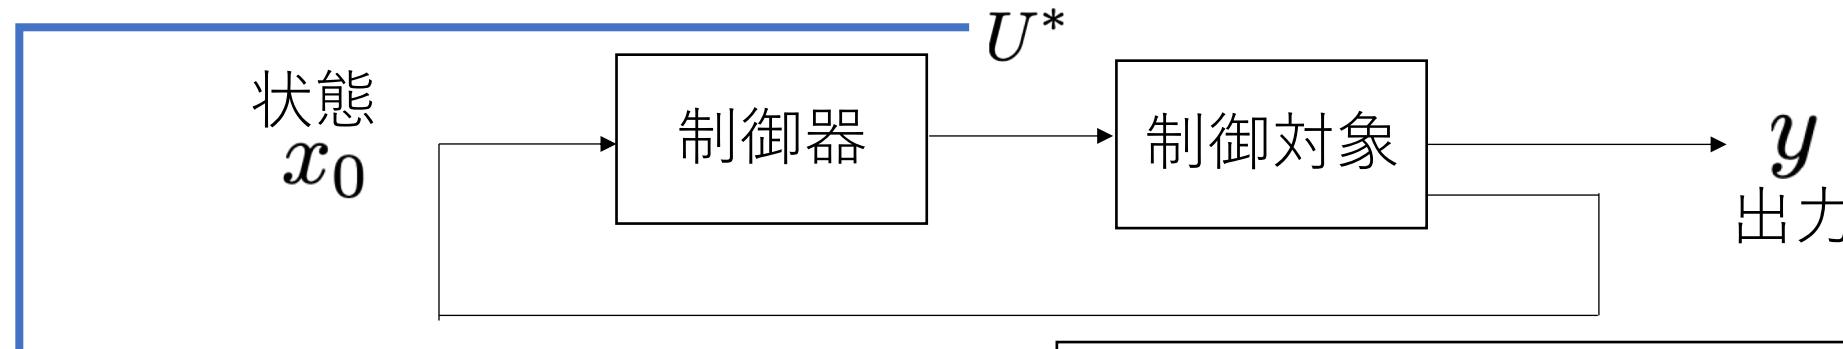
2021 制御部門マルチシンポジウム

▼ 分類型ニューラルネットワークを用いた
スペース最適制御器の近似

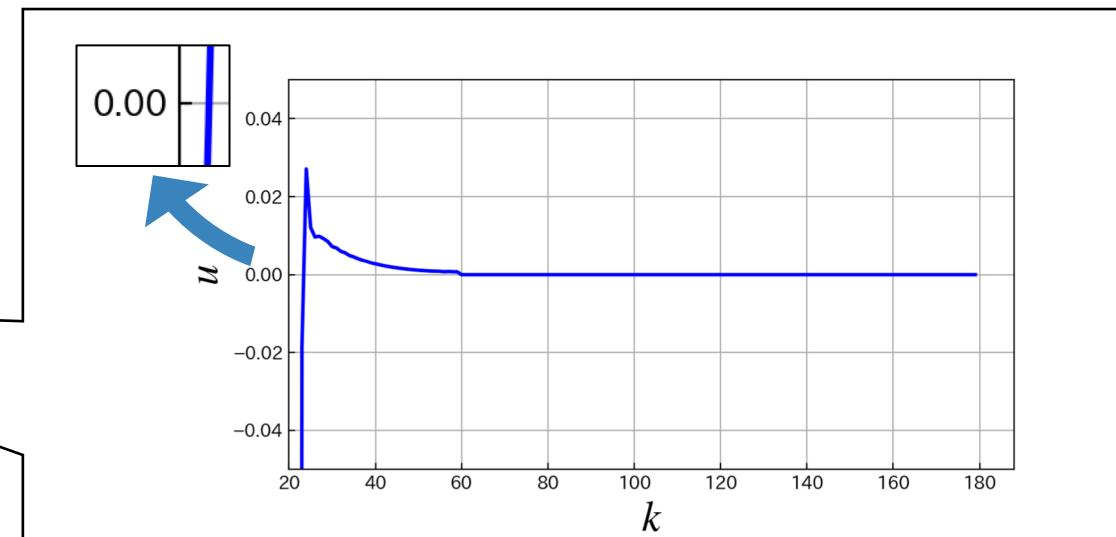
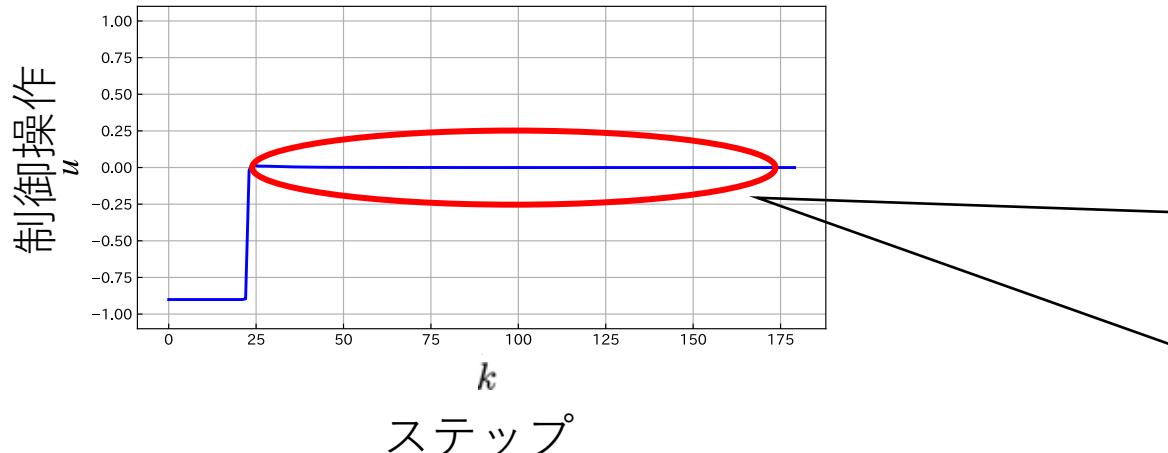
慶應義塾大学 ○松永 那瑠 井上正樹

研究背景: 制御における動的スペースモデリング^[1]

制御操作がスペースに
→ エネルギーや故障率を低減



制御操作(列)=ほとんど入力0



研究背景: スパース最適制御器

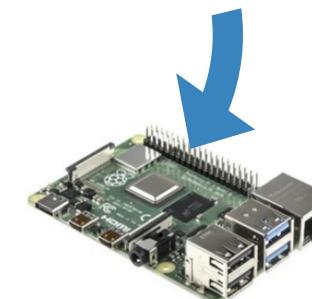
[2]
スパース最適制御器: L^1 最適制御問題を繰り返し解く

ex) 評価関数 $J(X, U) = x_N^\top Px_N + \sum_{k=0}^{N-1} \{x_k^\top Qx_k + |u_k|\}$ $\longrightarrow L^1$ ノルム

$$\begin{array}{l} \min_U J(X, U) \\ \text{sub.to } x_{k+1} = Ax_k + Bu_k \end{array} \rightarrow U^*$$

課題: 計算量が多い

→処理能力の小さいデバイスに適用困難 😞

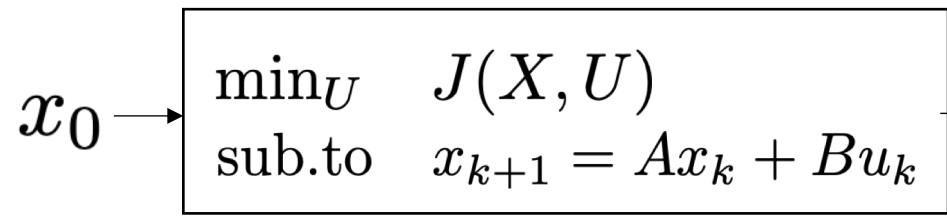


負荷大!

本発表: スパース最適制御器の計算負荷を低減する手法について検討

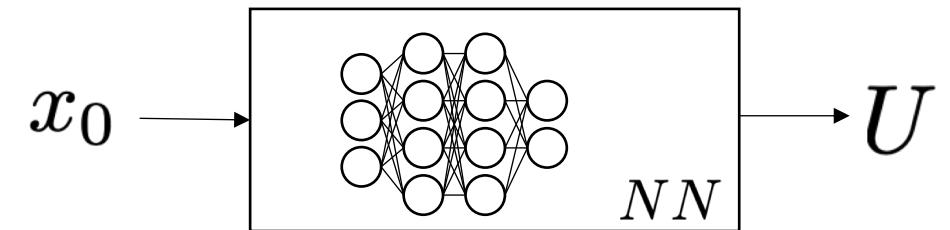
計算負荷低減のためのアプローチ: NNによる近似^{[3], [4]など}

◆ (実時間)最適制御



計算量大 ☹

◆ NNを用いて近似



計算量減 ☺

入出力関係を学習して最適制御器を近似
→計算量が軽減

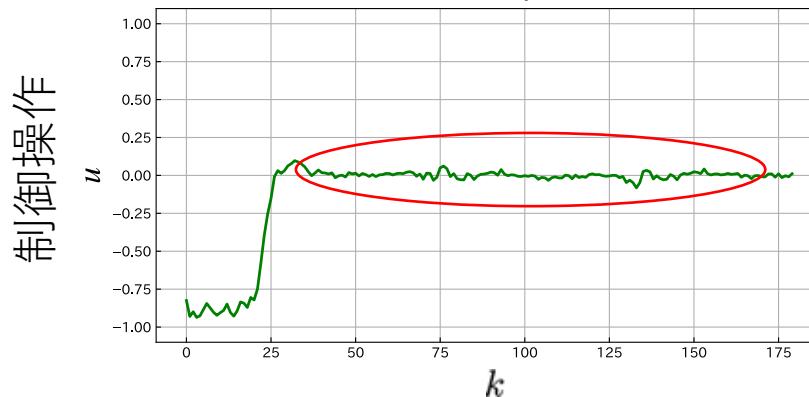
スパース最適制御器の近似 ~回帰型と分類型~

従来:回帰型NN

- ✓ **連続**的な数値を推論
(多くの先行研究で利用)
[3], [4]など

回帰型NNで制御すると…

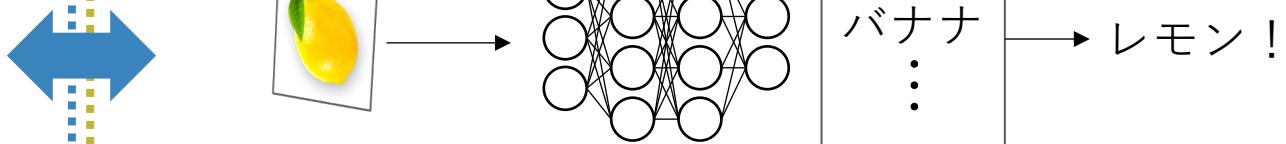
制御操作が非零となる時刻が増加



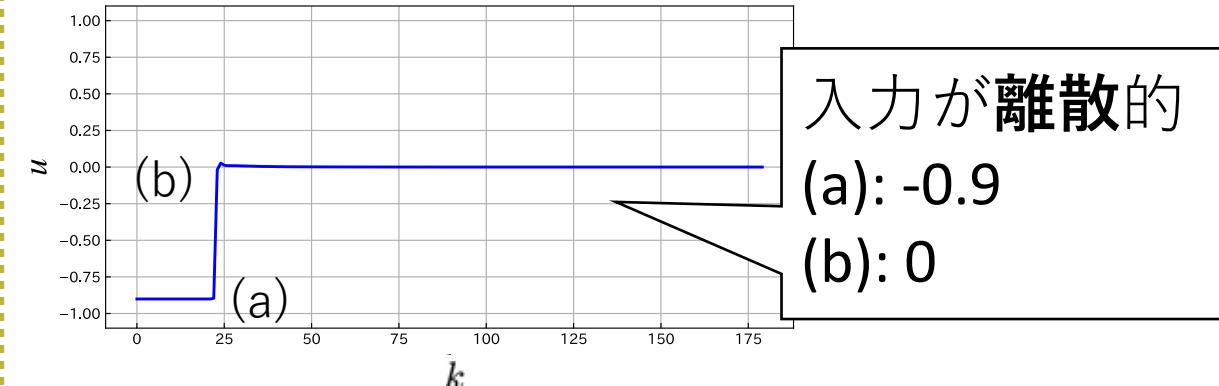
スパース性を失う

提案: 分類型NN

- ✓ 正解候補(離散的)の中から最適要素を決定 (通常は画像認識などで利用)



スパース最適制御は…



仮説:スパース性の表現は**分類型NN**が適している

発表の流れ

- ◆ 次のスパース最適制御問題(L^1 最適制御問題)で記述される最適制御器を扱う

$$\min_U \quad J(X, U) = x_N^\top Px_N + \sum_{k=0}^{N-1} \{x_k^\top Qx_k + |u_k|\} \quad (\text{評価関数})$$

$$\text{sub.to} \quad x_{k+1} = Ax_k + Bu_k, \quad k \in \mathcal{I}$$

$$h(x_k, u_k) \leq 0, \quad k \in \mathcal{I} \quad (\text{入力, 状態制約})$$

$$X = [x_0^\top, \dots, x_N^\top]^\top, \quad U = [u_0, \dots, u_{N-1}]^\top, \quad \mathcal{I} := \{0, \dots, N-1\}$$

①学習モデルの提案1: **分類型NN**による近似

②学習モデルの提案2: **Dual-Net**による近似

分類型NNの拡張系

学習モデル1: 分類型NNによる近似

目的: 最適制御問題の最適解 U^* の近似解 U^\dagger を得る分類型NNの設計

※ 分類型NNモデルの出力設定

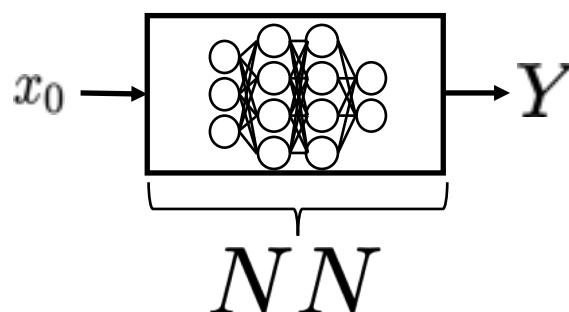
$$U^\dagger := [u_0^\dagger, \dots, u_{N-1}^\dagger]^\top$$

$$u_k^\dagger \in \{-1, 0, 1\}$$

離散値(今回は3値)から1つ選択して出力

✓ 提案する近似モデル: 二段階構造

次ページで説明

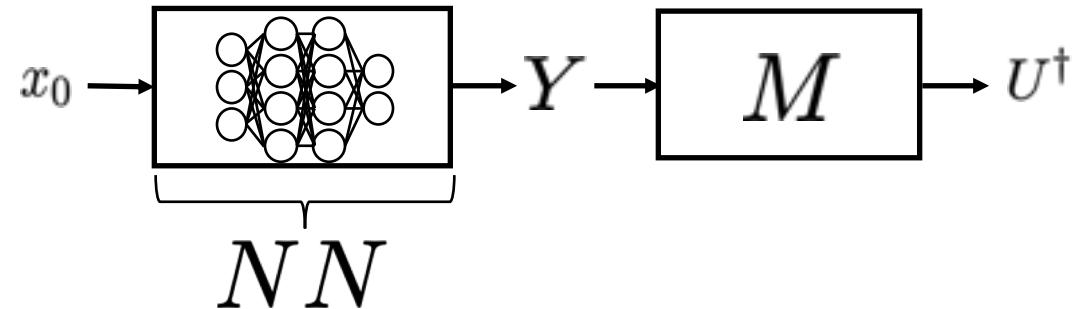


$$U^\dagger = M(Y)$$

$$Y = f_{\text{NN}}(x_0)$$

学習モデル1: 分類型NNによる近似

- ✓ 分類型NNモデルの構成要素



$$Y = [Y_0, \dots, Y_k, \dots, Y_{N-1}]^\top$$

$$Y_k = [y_k^{-1}, y_k^0, y_k^1]^\top$$

$$\therefore u_k^\dagger \in \{-1, 0, 1\}$$

$$\rightarrow Y \in \mathbb{R}^{3N}$$

$$M(Y) = [m(Y_0), \dots, m(Y_{N-1})]^\top$$
$$m(Y_k) = \begin{cases} -1 & \text{if } \max\{Y_k\} = y_k^{-1} \\ 0 & \text{if } \max\{Y_k\} = y_k^0 \\ 1 & \text{if } \max\{Y_k\} = y_k^1 \end{cases}$$

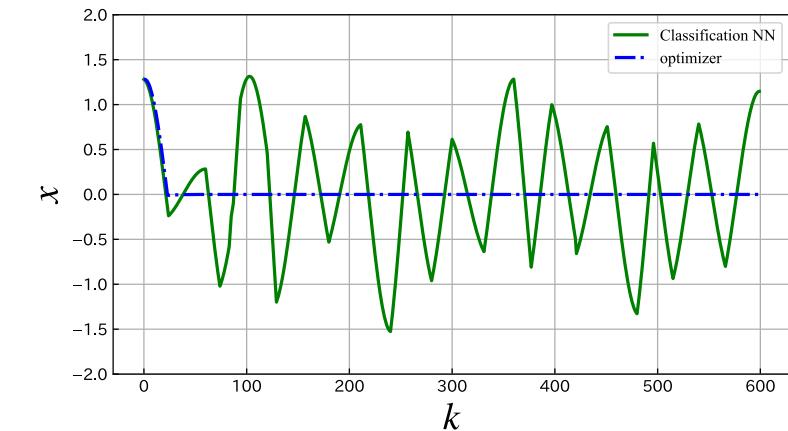
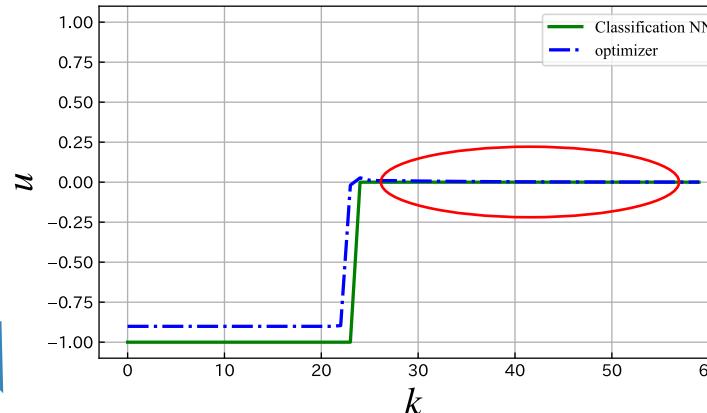
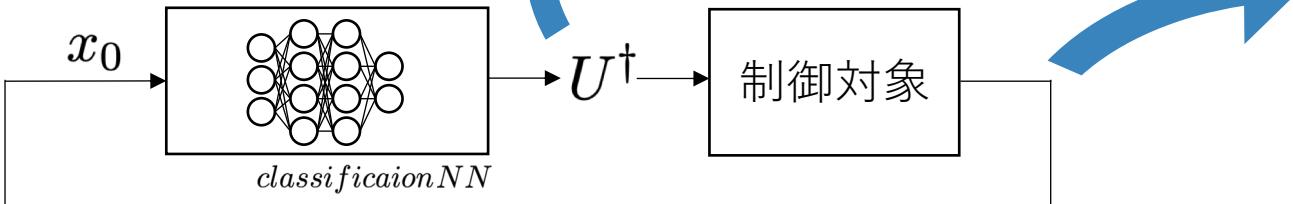
ex) $Y_k = [0.03, 0.07, 0.9]^\top$ の場合

$$u_k^\dagger = m(Y_k) = 1$$

学習モデル1: 数値シミュレーション

✓ スパースな U^\dagger が得られた 😊

— : 最適制御器
— : 分類型NN



✓ 状態が収束しない

状態 L^2 ノルム(目標値への制御性能)が悪化 😞

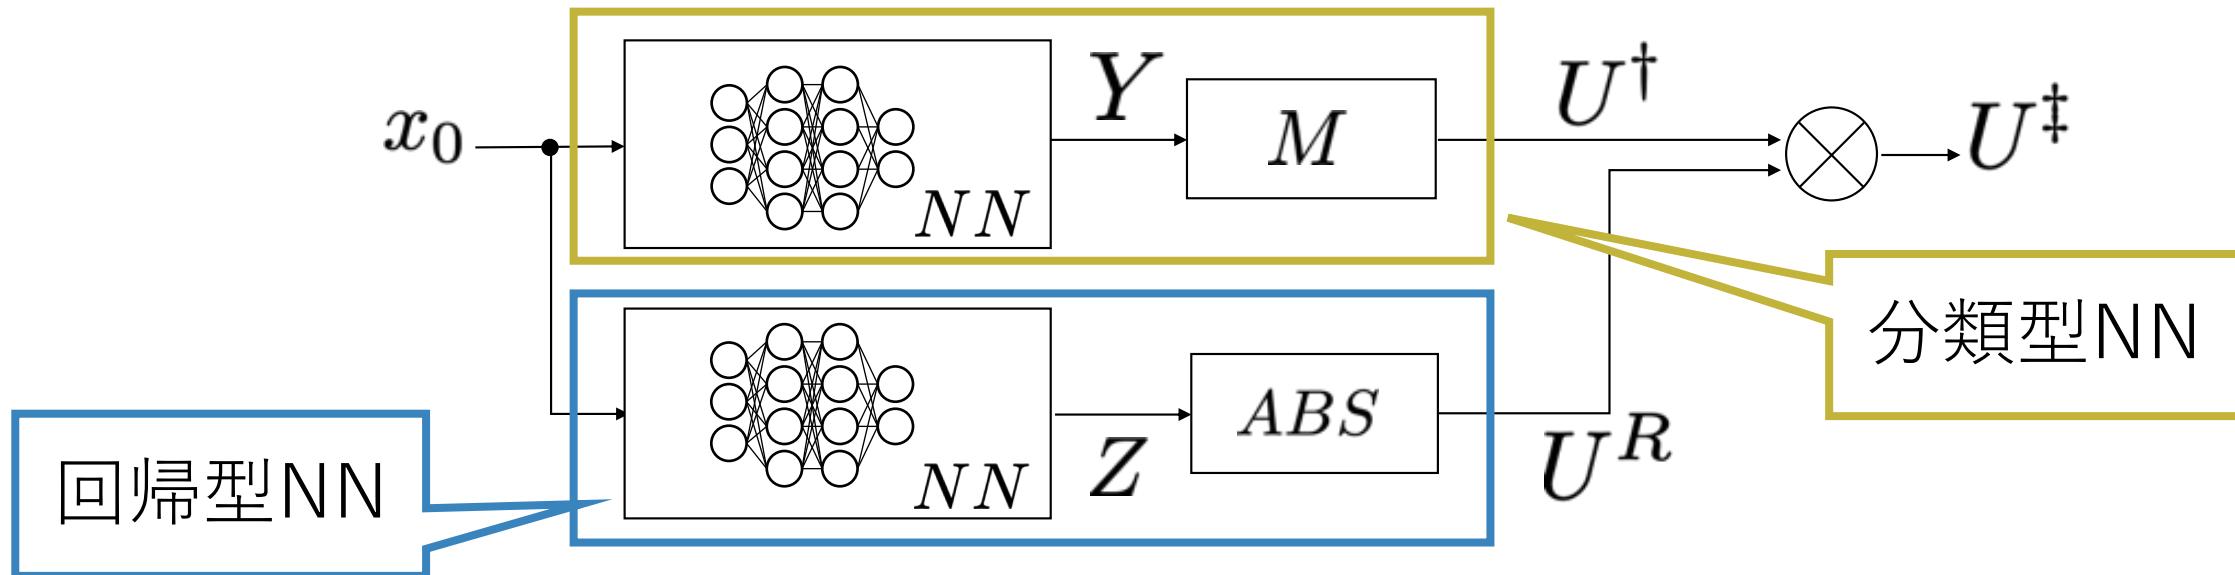
	分類型NN	回帰型NN	最適制御器
😊 入力休止率	60%	21.7%	56.7%
😊 実行時間	0.0083s	0.0263s	0.25s
😞 L^2 (状態)	367.96	20.77	20.19

入力休止率: $u_k \approx 0$ の割合

↑
原因: 制御操作が固定化
→ 精密な操作を加えられない

学習モデルの提案2: Dual-Netによる近似

目的: 最適制御問題の最適解 U^* の近似解 U^\ddagger を得る分類型NNの設計



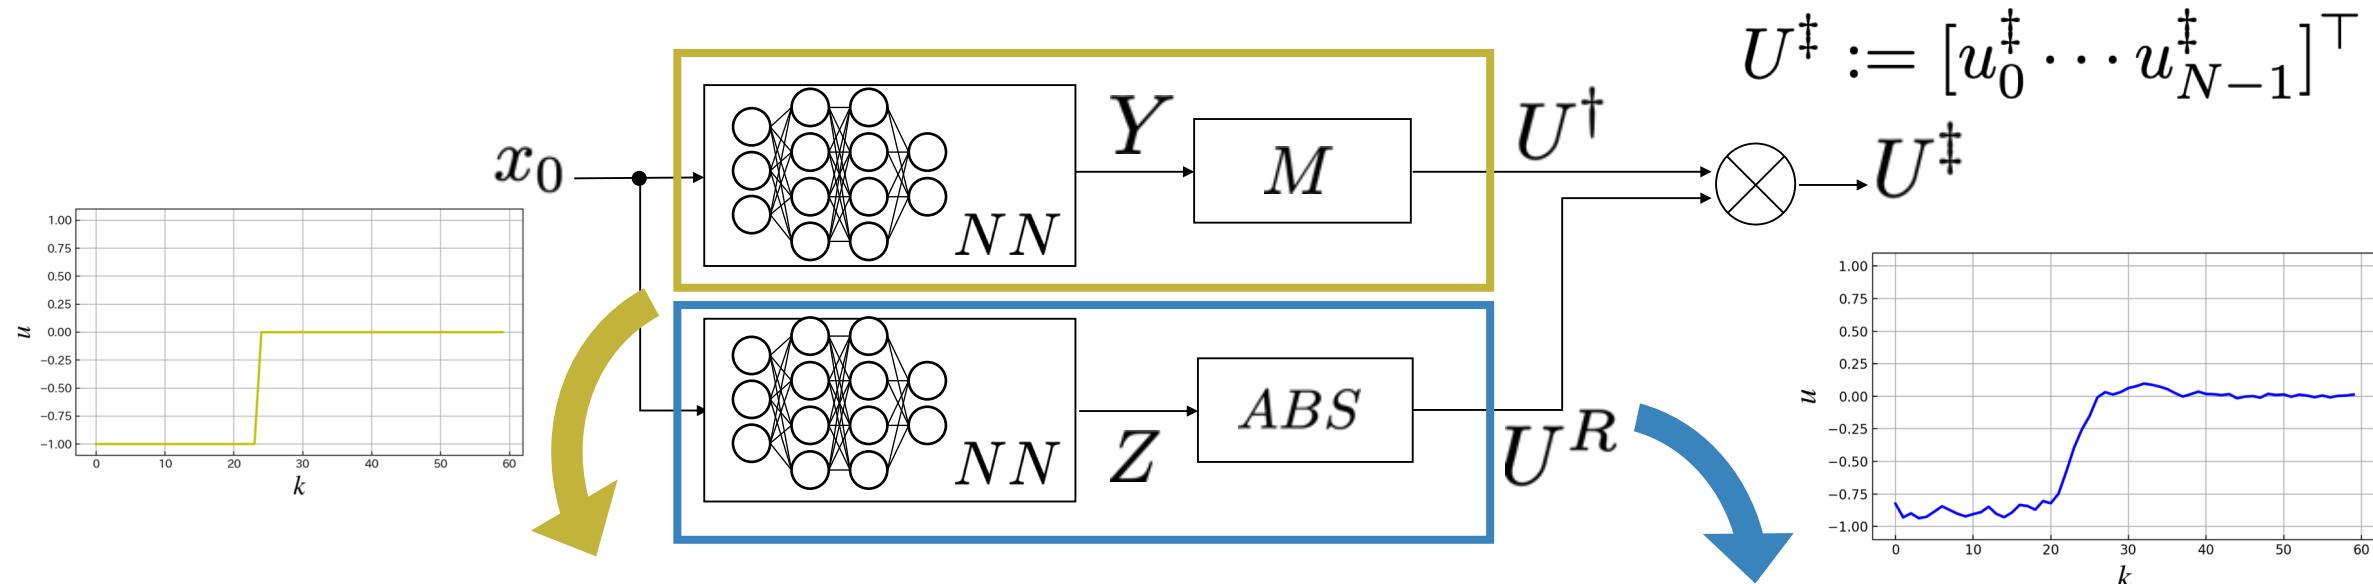
◆ Dual-Net: 分類型NNと回帰型NNを併用・それぞれに役割

$$U^\ddagger = \underline{U}^\dagger \circ \underline{U}^R$$

$$U^R := [u_0^R \cdots u_{N-1}^R]^\top$$

次ページで説明

学習モデルの提案2: Dual-Netによる近似



分類型NN部分: U^* の**符号**を推論

擬似的な量子化器の役割

($u_k^\dagger = \pm 0$ 近辺で閾値)

→ u_k^\dagger の符号 = u_k^+ の符号

回帰型NN部分: U^* の**絶対値**を推論

$$U^R = \text{ABS}(Z)$$

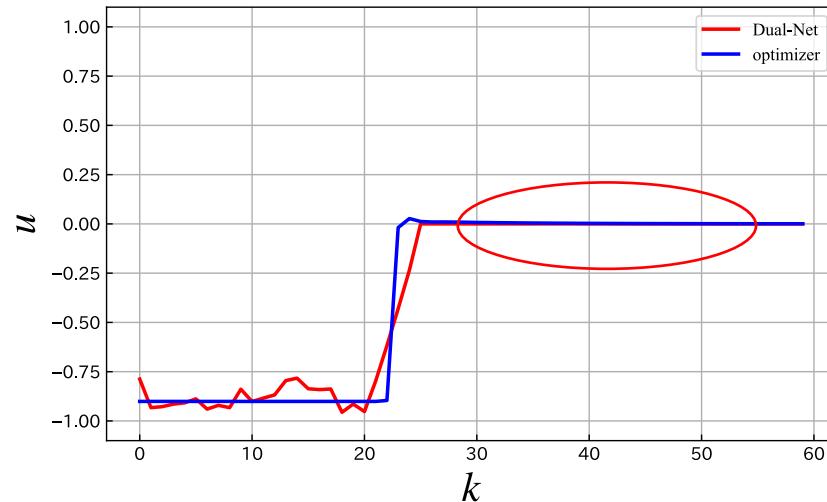
$$:= [|z_0|, \dots, |z_k|, \dots, |z_{N-1}|]^\top$$

$$Z = g_{\text{NN}}(x_0) \quad (\text{NNの出力})$$

→ 全ての要素は符号が正に変換

学習モデル2: 数値シミュレーション

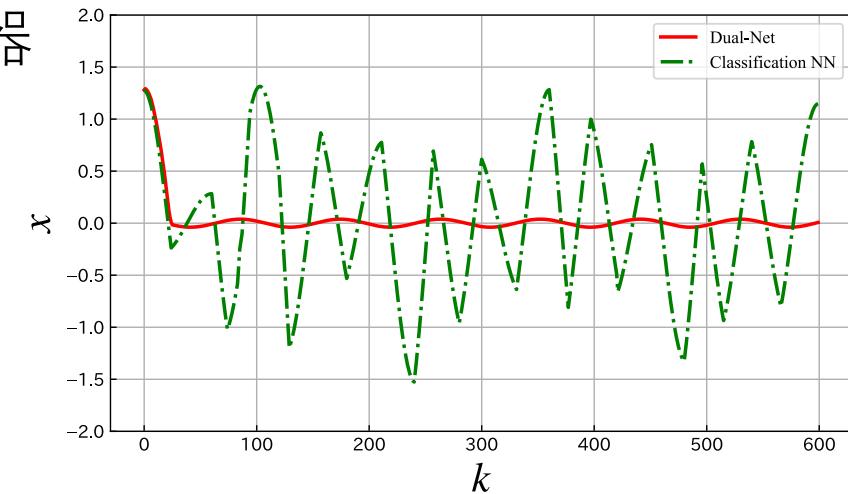
◆ 制御操作



✓ スパース性再現 😊

- 最適制御器
- 分類型NN
- Dual-Net

◆ 状態



✓ 制御操作の大きさを精密に推論 😊

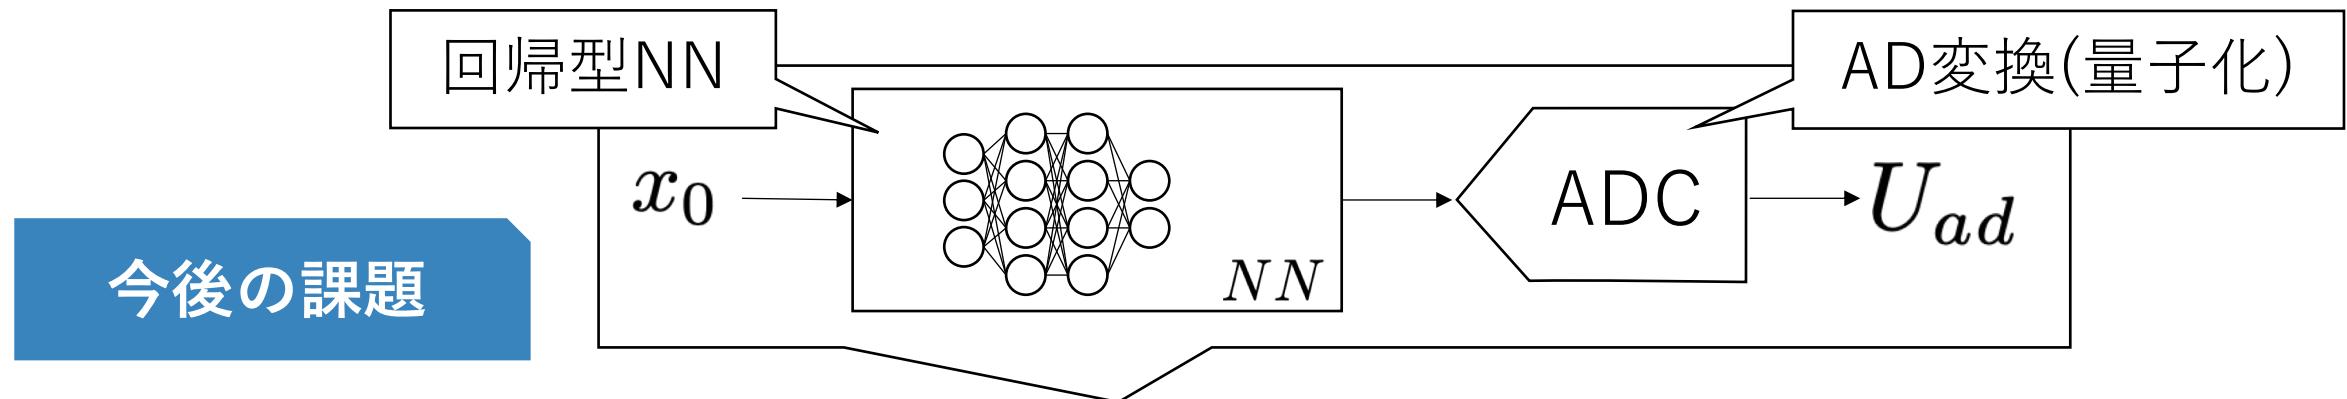
	Dual-Net	分類型NN	回帰型NN	最適制御器
入力休止率	58.3%	60%	21.7%	56.7%
実行時間	0.0605s	0.00828s	0.0263s	0.25s
$L^2(\text{状態})$	21.19	367.96	20.77	20.19

スパース性と
状態抑制性能を両立

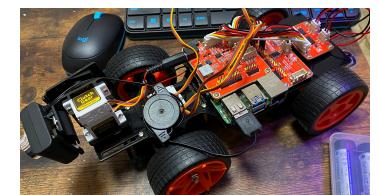
まとめと今後の課題

まとめ

- ①スパース最適制御近似に分類型NNを提案、性能を評価
- ②分類型NNの応用系としてDual-Netを提案、性能を評価



- ①静的な量子化器を有した回帰型NNとの差別化
- ②実機を用いた最適制御器の近似、有用性を検証



補足資料: 数値実験で使用したNNの設定

- 分類型NN及び
Dual-Net分類型NN部分

Table 2: Settings of Classification NN

Structure	$2 \times 64 \times 64 \times 180$
Loss function	BCEWithLogitsLoss
Optimizer	Adam
Batch size	100
Activation function	ReLU
Activation function (output layer)	Identity function
Number of training [epoch]	10

- 回帰型NN及び
Dual-Net回帰型NN部分

Table 3: Settings of Regression NN: part of Dual-Net

Structure	$2 \times 64 \times 64 \times 60$
Loss function	MSELoss
Optimizer	Adam
Batchsize	100
Activation function	ReLU
Activation function (output layer)	Identity function
Number of training [epoch]	10

- 学習データ個数

分類型/回帰型NN: 20000個

Dual-Net: 分類型/回帰型部分でそれぞれ10000個

スパース最適制御の近似

[N. Matsunaga et al, MSCS, 2021]で発表



目的: スパース最適制御器に要する計算負荷を軽減

アプローチ: **分類**型NNモデル(深層学習)で近似

松永那瑠
2020年度 M1

